

INSTITUTO TECNOLÓGICO DE BUENOS AIRES

22.05 ANÁLISIS DE SEÑALES Y SISTEMAS DIGITALES

Trabajo Práctico Final

Investigación y Desarrollo de un Algoritmo Seguidor de Objetos

Grupo 3

MECHOULAM, Alan	58438
LAMBERTUCCI, Guido Enrique	58009
RODRIGUEZ TURCO, Martín Sebastian	56629
LONDERO BONAPARTE, Tomás Guillermo	58150

Profesores

Jacoby, Daniel Andres
Belaustegui Goitia, Carlos F.
Iribarren, Rodrigo Iñaki

Presentado: ??/07/20

Illumination-invariant Object Tracking Using Optical Flow, Correlation Filtering and Color-Distribution-Based Image Masking

Mechoulam Alan, Lambertucci Guido, Rodriguez Turco Martín, Londero Bonaparte Tomás
Instituto Tecnológico de Buenos Aires, Argentina

Resumen

En el siguiente trabajo se presenta la investigación y desarrollo de un proceso de seguimiento de un objeto en tiempo real siendo conocida su posición inicial. Se utilizaron los algoritmos de Shi-Tomasi, Optical Flow de Lucas-Kanade, filtros de Kalman, de probabilidad de distribución de color y de correlación para lograr robustez ante cambios en la iluminación, occlusiones parciales o totales y cambios bruscos en la trayectoria incluso durante una ocultación.

I. INTRODUCCIÓN

Una imagen puede ser interpretada como una función bidimensional $f(x, y)$, donde tanto x como y representan en un plano el espacio visualizado, mientras que la misma función $f(x, y)$ es la intensidad de la imagen bajo un punto dado. Cuando x , y y $f(x, y)$ son valores cuantizados y discretizados, la imagen se transforma en una imagen digital.

El procesamiento de dichas se define como el conjunto de técnicas aplicadas a estas imágenes, con el objetivo extraer información de ellas. Estas actividades cubren un campo que abarca un sin fin de aplicaciones, ya que se vale de máquinas capaces de detectar la totalidad del espectro electromagnético. Esto significa que se pueden obtener imágenes generadas por fuentes que captan información la cual para los humanos no se asocian con imágenes propiamente dichas, como lo son las ondas de radio, entre tantas otras.

Es posible considerar tres tipos de procesos computarizados en el procesamiento de imágenes, basándose en el nivel de tratamiento que se aplique, siendo así clasificados en bajo, medio y alto nivel. Los primeros incluyen actividades tales como reducción de ruido y aumento de contraste, tareas caracterizadas por el hecho de que tanto la entrada como la salida son imágenes. Las actividades de medio nivel de procesamiento incluyen trabajos de segmentación, es decir, identificar regiones u objetos dentro de las imágenes, descripción y clasificación de dichos elementos. Es así que esta categoría es destacada por sus salidas, ya que suelen ser información extraída de las imágenes a la entrada. Por último, los procesos de alto nivel se caracterizan por no solo reconocer objetos y analizarlos, sino también por darles un tratado normalmente asociado con la visión, tales así como “darles sentido” [1].

Dada una señal continua a la entrada del sistema, una imagen sufre de dos procesos claves: **cuantización** y **discretización**. Si bien ambos refieren a tomar variables continuas y almacenarlas en memoria como variables discretas, se realiza esta diferenciación entre ambas ya que la primera hace referencia a la amplitud de la señal mientras que la segunda a coordenadas, que para el caso del estudio de imágenes, se refiere a pixeles. Estos son el mínimo elemento que compone una imagen digital y se pueden pensar como un cuadrado de color uniforme.

Ejemplificando lo anterior, se toma una entrada al sistema, como puede ser la presentada en la Figura (1), la cual, como ya se ha mencionado, es continua en x , y y $f(x, y)$.

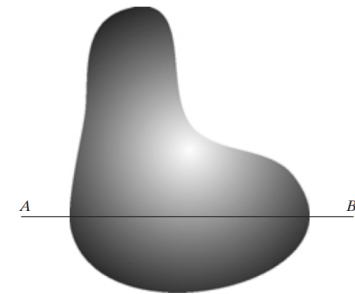


Figura 1: Entrada continua al sistema.

Por lo tanto, se deben tomar coordenadas finitas, por ejemplo, aquellas que se encuentran sobre la recta AB, y asignarle a cada una un valor dado de amplitud. En la Figura (2) se observa como una recta continua paralela al eje x (horizontal), la cual posee ciertas variaciones aleatorias dadas por el ruido existente, es dividida en una cierta cantidad de posiciones equiespaciadas (discretización), marcadas con cuadraditos blancos sobre la curva, asignándoles un nivel específico en la escala de grises (cuantización), marcado con una linea negra por la izquierda de dicha escala.

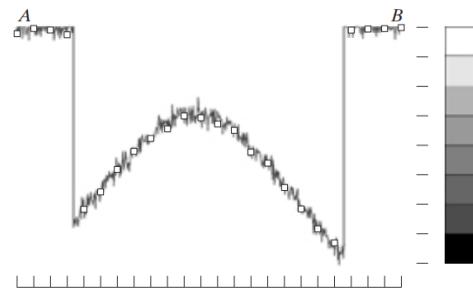


Figura 2: Amplitud de la escala de grises en la recta AB y muestreo de valores.

Realizando el mismo proceso para todos los niveles de discretización en el eje y (vertical), se obtiene finalmente una imagen digitalizada, la cual se la compara a continuación con la original [2].

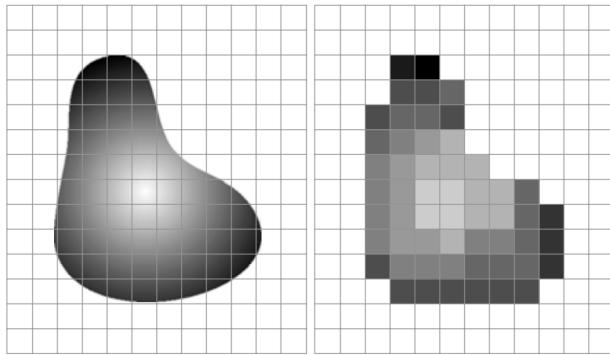


Figura 3: Imagen original comparada con la imagen digitalizada a procesar.

Este trabajo se centra en procesos de medio nivel. Dicha definición es muy amplia, por lo cual es necesario acotar este camino. Es por ello que se decidió focalizarse en el seguimiento de objetos en imágenes en movimiento. Se buscó que, dada ciertas condiciones iniciales conocidas (brindadas por el usuario) en una imagen en movimiento en tiempo real, tomar un conjunto de datos de x , y y $f(x, y)$ para así seleccionar un elemento y seguir su trayectoria a través del tiempo. Como hipótesis se plantea que:

- El objeto no cambiará rápidamente de color ni su iluminación o exposición-

Para esto, se utilizaron los algoritmos de Shi-Tomasi, Optical Flow de Lucas-Kanade asimismo como filtros de correlación, de Kalman y de probabilidad de distribución de color.

II. INVESTIGACIÓN

II-A. Optical Flow

El campo de movimiento de una imagen es el movimiento real del objeto en el espacio proyectado sobre el plano de la imagen. El Optical Flow (flujo óptico) se define como el flujo de la intensidad en escala de grises en el plano de la imagen, a medida que evoluciona en el tiempo. También se puede interpretar el flujo de la imagen como el movimiento aparente de esta basado en la percepción visual, teniendo dimensión de velocidad $\vec{V} = (V_x, V_y)$. Si el Optical Flow se determina de dos imágenes consecutivas, aparece un vector de desplazamiento \vec{d} de las cualidades elegidas, entre el cuadro n y el $n+1$.

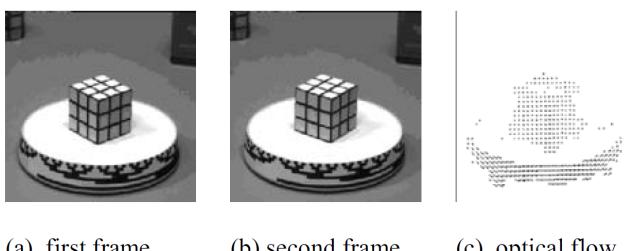


Figura 4: Cubo de rubik rotando en una mesa.

Para la implementación del algoritmo existen varios caminos, como lo es, por ejemplo, el basado en calculo de

gradientes de la imagen total. Existe otro que utiliza solo ciertos puntos que se determinan constantes de la imagen. El el presente se emplea el método piramidal de Lucas-Kanade.

II-A1. Lucas-Kanade: Este algoritmo consta del uso de información obtenida a partir de la intensidad del gradiente espacial para buscar la posición que mejor se acomoda a una imagen en movimiento [4] [6]. Algunas de las hipótesis que postula Lucas-Kanade son:

- Los movimientos entre cuadros consecutivos son pequeños. Tan pequeños como un pixel.
- La intensidad de los objeto se mantiene constante cuadro a cuadro.

Este algoritmo se basa en el principio de “divide y conquistarás” al realizar la tarea de detectar movimiento en toda la imagen en problemas más sencillos. El proceso consta de dividir la pantalla en un árbol cuaternario. Esto lo hace debido a que se requiere que las hipótesis de Lucas-Kanade deben cumplirse, se toma una pequeña parte de la imagen, del menor tamaño posible, donde tienden a cumplirse las condiciones necesarias del algoritmo. De allí se calcula recursivamente cada partición hasta el primer nivel.

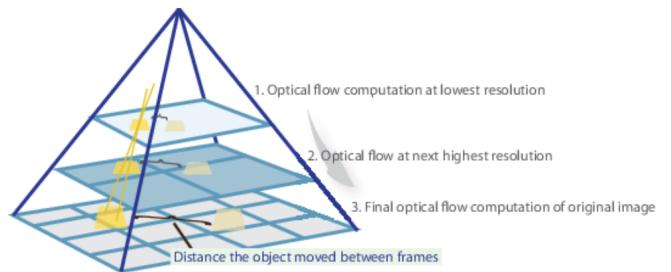


Figura 5: Cálculo del Optical Flow.

II-B. Shi-Tomasi

Por su parte, el algoritmo de Shi-Tomasi se basa en el algoritmo de Harris para la detección de bordes. El funcionamiento del algoritmo se basa en asignarle un valor a cada pixel del bitmap recibido, y si el valor del pixel es mayor a cierto límite se determina que este corresponde a una esquina. El valor asignado al pixel se obtiene utilizando dos autovalores de una matriz Z . Una función recibe estos autovalores, para poder manipularlos y devolver el valor. La diferenciación entre el algoritmo de Harris y el de Shi-Tomasi, es que mientras Harris utiliza la función mencionada previamente, Shi-Tomasi decide utilizar únicamente los autovalores [9].

Los valores de cada pixel se determinan de la siguiente manera:

$$R = \det(Z) - k(\text{trace}Z)^2 \quad (1)$$

$$\det(Z) = \lambda_1 \cdot \lambda_2 \quad (2)$$

$$\text{trace}Z = \lambda_1 + \lambda_2 \quad (3)$$

Figura 6: Valor de pixel para algoritmo de Harris

$$R = \min(\lambda_1, \lambda_2) \quad (4)$$

Figura 7: Valor de pixel para algoritmo de Shi-Tomasi

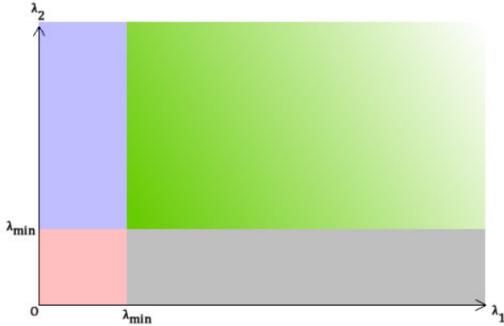


Figura 8: Detección de bordes Shi-Tomasi.

- La zona verde corresponde a ambos λ_1 y λ_2 mayores al valor límite, por lo que estos píxeles son tomados como esquina.
- La zona azul y gris corresponden a que uno de los autovalores es menor al límite.
- La zona roja corresponden a ambos autovalores menores al mínimo.

II-C. Filtro de Kalman

El filtro de Kalman es un filtro recursivo que busca estimar el estado de un sistema dinámico lineal discretizado de dimensión n mediante una serie mediciones con ruido a partir de la descripción del modelo físico que rige las variables del vector de estado [7], [8].

II-C1. Planteo del problema: Dado un proceso estocástico lineal en tiempo discreto definido por

$$x_k = Ax_{k-1} + w_{k-1}^1 \quad (5)$$

donde $x_k \in \mathcal{R}^N$ y siendo una medición en tiempo k definida por

$$z_k = Hx_k + v_k \quad (6)$$

con $z_k \in \mathcal{R}^m$, donde w_k y v_k son variables aleatorias que representan el ruido del proceso y de observación respectivamente, las cuales se asumen que son independientes entre sí y con distribuciones de probabilidad normales multivariadas definidas como

$$p(w) \sim N(0, Q)$$

$$p(v) \sim N(0, R)$$

donde Q y R son las matrices de covarianza del ruido del proceso y ruido de medición respectivamente, las cuales se

¹Se omitió por simplicidad la función de control.

asumen constantes; donde la matriz de transición de estados A de dimensión $n \times n$ —siendo n la dimensión de estados dinámicos del modelo— define la relación entre estados del paso $k-1$ al paso k sin contar el ruido del proceso; donde la matriz de transición de observación H de dimensión $m \times n$ —siendo m la dimensión del vector de medición— fija la relación entre el espacio de los observables medidos y el espacio de las variables del vector de estados, sin contar el ruido de medición; y finalmente donde el estado del filtro puede representarse como $\hat{x}_{k|k}$ y $P_{k|k}$, siendo estos el estimador del vector de estados a posteriori dadas las mediciones hasta un tiempo k , y el estimador de la matriz de covariaza a posteriori dadas las mediciones hasta un tiempo k respectivamente. Se puede definir la operación del filtro de Kalman separando a esta en dos fases: la predicción, y la corrección.

II-C2. Ecuaciones de predicción:

$$\hat{x}_{k|k-1} = A\hat{x}_{k-1|k-1} \quad (7)$$

$$P_{k|k-1} = AP_{k-1|k-1}A^T + Q \quad (8)$$

II-C3. Ecuaciones de observación:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k y_k \quad (9)$$

$$P_{k|k} = (\mathbb{I} - K_k H)P_{k|k-1} \quad (10)$$

donde,

$$y_k = z_k - H\hat{x}_{k|k-1} \quad (11)$$

$$S_k = HP_{k|k-1}H^T + R_k \quad (12)$$

$$K_k = P_{k|k-1}H^T S_k^{-1} \quad (13)$$

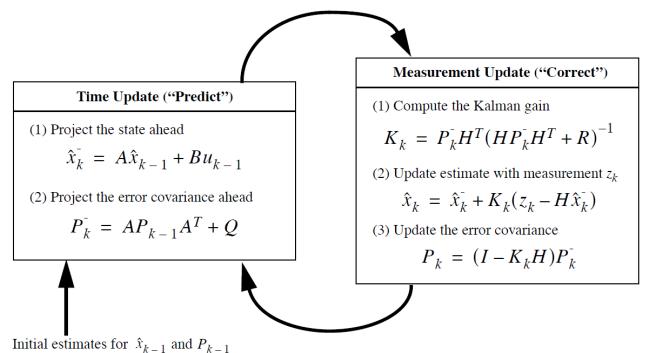


Figura 9: Funcionamiento completo del filtro Kalman simple [8].

En la Figura (10) se puede observar el funcionamiento del algoritmo con un vector de estados dinámicos de dimensión dos compuesto por las coordenadas (x, y) sobre el plano cartesiano. Realizando mediciones periódicamente, se comparan dos curvas. Por un lado, una senoidal con un ruido gaussiano montado sobre ella, simulando una serie de mediciones con ruido, y por el otro lado, la estimación obtenida a partir del filtro desarrollado.

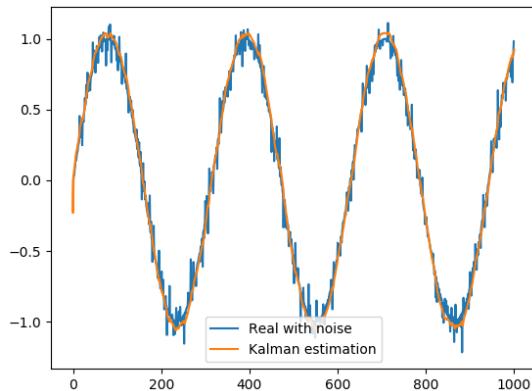


Figura 10: Seno con ruido comparada con estimación de Kalman.

II-D. Filtros de Correlación:

El filtro de correlación o también conocido como “Matched Filter” [10] en inglés, se obtiene al calcular la correlación de una señal conocida, o “kernel”, con una señal desconocida con el propósito de detectar este kernel en la última señal. Esto último es equivalente a convolucionar la señal desconocida con la inversión temporal del conjugado de la conocida. Este filtro es el óptimo lineal que maximiza la relación señal a ruido (SNR) en presencia de ruido aditivo.

Existen diversas maneras de calcular esta correlación, los dos métodos propuestos fueron:

- Cuadrados mínimos: Se basa en el cálculo de cuadrados mínimos entre el kernel y la imagen mientras se realiza la convolución y corresponde a la siguiente ecuación

$$R(x, y) = \frac{\sum_{x', y'} (T(x', y') - I(x + x', y + y'))^2}{\sqrt{\sum_{x', y'} T(x', y')^2 \cdot \sum_{x', y'} I(x + x', y + y')^2}} \quad (14)$$

- Estimación de la correlación: Se calcula la correlación por definición del frame con respecto al kernel a medida que se desliza por la imagen, le corresponde la siguiente fórmula

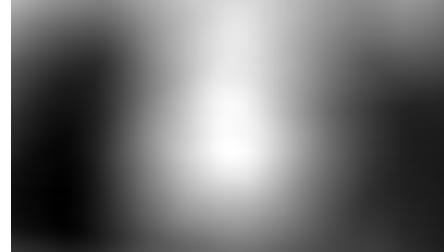
$$R(x, y) = \frac{\sum_{x', y'} (T(x', y') \cdot I(x + x', y + y'))}{\sqrt{\sum_{x', y'} T(x', y')^2 \cdot \sum_{x', y'} I(x + x', y + y')^2}} \quad (15)$$

Donde R es la función de resultado, I la señal desconocida, y T el template o kernel.

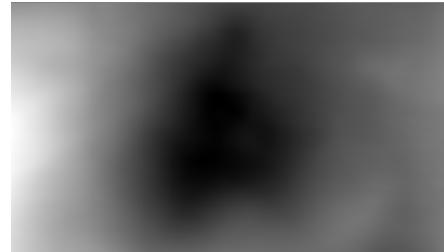
En la Figura (11) se puede observar una imagen y el resultado del cálculo de correlación utilizando la correlación por cuadrados mínimos y por correlación.



(a) Imagen Fuente.



(b) Correlación utilizando definición.



(c) Correlación utilizando cuadrados mínimos.



(d) Kernel.

Figura 11: Aplicación del algoritmo de correlación.

Se puede apreciar como el punto más oscuro de la pantalla indica el punto de mayor correlación entre la imagen fuente y el kernel seleccionado para el algoritmo de cuadrados mínimos (Figura (11c)) mientras que el mas claro indica la mayor correlación para el otro (Figura (11b)).

II-E. Filtros basados en distribución de probabilidad de Hue:

Los filtros de color tradicionales usualmente se basan en la detección de un color específico con la adición de una cierta tolerancia para poder incluir una gama de colores más amplia. Sin embargo dicha elección resulta ser demasiado restrictiva cuando aparecen sombras o cambios de iluminación. Es por eso que una alternativa más permisiva es la de utilizar máscaras que permitan el paso de ciertos colores según una función de masa de probabilidad dada. Dicha distribución se computa usando como semilla el objeto que deseamos seguir.



(a) Kernel

II-F. Espacios de Color HSV y CIE-L*a*b*:

El espacio de color HSV, o hue-saturation-value logra representar a un color mediante tres ejes distintos. A diferencia del espacio de colores usual, RGB, que describe un color mediante sus componentes de rojo, verde y azul, en el espacio HSV se describe mediante la oscuridad/luminosidad del color, al cual se le asigna la componente value; la cantidad de pigmentación o pureza del color, al cual se le asigna la componente de saturación; y finalmente la componente de hue, que describe el *chroma* según la teoría de colores, es decir la posición en la rueda de colores.

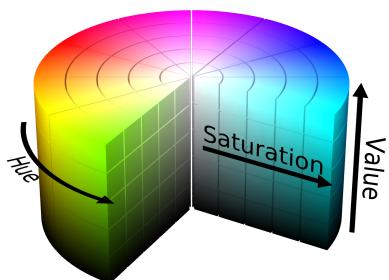


Figura 13: Espacio de colores HSV representado como un cilindro.

Este espacio se puede representar como un cilindro, como se demuestra en la Figura (13). Si bien la componente de value representa la oscuridad/luminosidad de un color, este modelo es incorrecto debido a que presenta uniformidades. Es por esto, que para obtener una verdadera representación de luminosidad se utiliza el espacio Lab. El espacio de color L*a*b* de la comisión internacional en iluminación o CIE por sus siglas en francés es un espacio de color perceptualmente uniforme que representa a un color mediante tres parámetros: lightness, a y b, siendo lightness un modelo correctamente calculado e uniforme de la luminosidad de un color, y a y b las componentes de rojo/verde y amarillo/azul del color respectivamente².

²Imagen atribuida en <https://opentextbc.ca/graphicdesign/chapter/colour-science/>

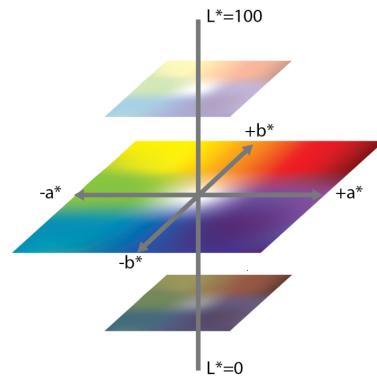


Figura 14: Espacio de colores CIE-Lab en coordenadas cartesianas.

III. APORTES Y DESARROLLO

III-A. Primer diseño

A partir de una selección del video proporcionada por el usuario se obtienen las mejores features del objeto deseado, utilizando el algoritmo de Shi-Tomasi. Luego, mediante el de Lucas-Kanade de Optical Flow se obtiene la evolución de dichas features en el tiempo. A este cúmulo de puntos se le calcula el centro de masas μ y el centro de inercia σ . Se rechazan los puntos de este cúmulo que se encuentren a una distancia mayor a $k_\sigma\sigma$ respecto al centro de masas, para luego calcular nuevamente dicho centro, el cual es el que se introduce en el filtro de Kalman como medición de la posición.

La dimensión del vector de estados del filtro de Kalman es de cuatro, poseyendo la posición y la velocidad tanto horizontal como vertical. La dimensión del vector de observación es de dos, dado que solamente se mide la posición horizontal y vertical del centro de masas. La matriz A queda definida por las ecuaciones que caracterizan el movimiento del objeto a seguir que, por simplicidad, se consideraron las ecuaciones cinemáticas de MRU, quedando entonces

$$\begin{pmatrix} x_{k-1} + dt \cdot v_{x_{k-1}} \\ y_{k-1} + dt \cdot v_{y_{k-1}} \\ v_{x_{k-1}} \\ v_{y_{k-1}} \end{pmatrix} = \begin{pmatrix} 1 & 0 & dt & 0 \\ 0 & 1 & 0 & dt \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} x_{k-1} \\ y_{k-1} \\ v_{x_{k-1}} \\ v_{y_{k-1}} \end{pmatrix} \quad (16)$$

Siendo,

$$A = \begin{pmatrix} 1 & 0 & dt & 0 \\ 0 & 1 & 0 & dt \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (17)$$

Luego, se tiene que la matriz de observación o de transición de medición queda definida por la transformación del espacio de observación al espacio real del vector de estados del filtro. Como los observables a medir forman parte del espacio real del vector de estados y son solo las posiciones, la matriz queda definida de manera simple

$$\begin{pmatrix} z_{x_k} \\ z_{y_k} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \cdot \begin{pmatrix} x_k \\ y_k \\ v_{x_k} \\ v_{y_k} \end{pmatrix} \quad (18)$$

Siendo,

$$H = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \quad (19)$$

Las matrices de covarianza del proceso Q y de medición R son cuadradas por definición, de dimensión cuatro y dos respectivamente. Además, son la forma $\mathbb{I} \cdot \xi$ dado que se asume independencia de las variables aleatorias, quedando

$$Q = \begin{pmatrix} \xi_Q & 0 & 0 & 0 \\ 0 & \xi_Q & 0 & 0 \\ 0 & 0 & \xi_Q & 0 \\ 0 & 0 & 0 & \xi_Q \end{pmatrix} \quad (20)$$

$$R = \begin{pmatrix} \xi_R & 0 \\ 0 & \xi_R \end{pmatrix} \quad (21)$$

Siendo ξ_Q y ξ_R las varianzas del proceso y de medición respectivamente.

Finalmente, $\hat{x}_{k|k}$ y $P_{k|k}$ toman la forma

$$\hat{x}_{k|k} = \begin{pmatrix} \hat{x} \\ \hat{y} \\ \hat{v}_x \\ \hat{v}_y \end{pmatrix} \quad (22)$$

$$P_{k|k} = \begin{pmatrix} \gamma_x & 0 & 0 & 0 \\ 0 & \gamma_y & 0 & 0 \\ 0 & 0 & \gamma_{v_x} & 0 \\ 0 & 0 & 0 & \gamma_{v_y} \end{pmatrix} \quad (23)$$

Siendo γ_i la varianza de cada variable de estado. Cabe notar que el modelo utilizado asume independencia entre las variables aleatorias por simplicidad.

Este algoritmo explicado, cuenta con grandes problemas. Dados dos objetos A y B , donde A es el objeto a seguir:

- Como el algoritmo de Shi-Tomasi tiende a colocar features en bordes bien definidos, y estos suelen ser los bordes externos de un objeto, si el objeto a seguir A pasa por delante de un objeto B con bordes bien definidos, las features del algoritmo de Optical Flow tienden a adosarse a los bordes del objeto B por más que este esté quieto.
- Si el objeto A pasase por detrás del objeto B inmóvil, todas las features sobre el objeto a seguir quedan adosadas al objeto B . Esto plantea un problema mucho más grande que el anterior, dado que no se puede utilizar la estimación del filtro de Kalman de manera confiable, debido a que cuando los features se queden quietos adosados en B , se sigue midiendo de todas formas y se sigue entregando esas mediciones al filtro de Kalman, por lo que la estimación de este se adosa también al objeto B .
- Profundizando en el ítem anterior, existe una ambigüedad entre que A pase de un movimiento MRU a que se quede completamente quieto y que A pase por detrás de B , dado que en ambas situaciones las features quedan quietas en el lugar donde A se haya quedado quieto o el lugar de la intersección entre A y B

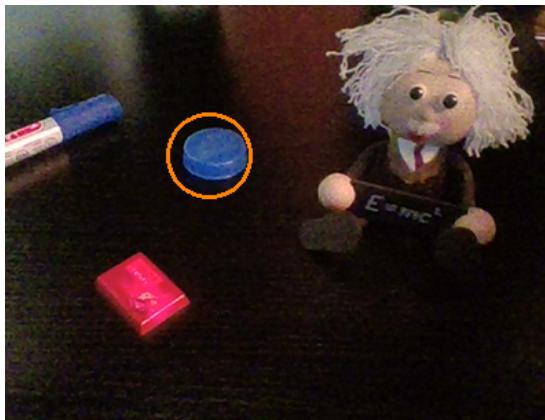
III-B. Segundo diseño

III-B1. Enmascaramiento Basado en HSV: La mejora propuesta para sortear estos problemas consiste en agregar un filtro de color, para diferenciar a A y a B por su color. La implementación de este filtro de color comienza en el momento en el que el usuario selecciona el área a seguir. Se calcula la mediana del color de la zona elegida, y ese color es transformado de formato RGB a formato HSV, o Hue-Saturation-Value, dado que es más sencillo definir una máscara de este modo. Dado x e y las coordenadas de los píxeles de la imagen, \vec{R}_k , \vec{G}_k y \vec{B}_k los vectores de píxeles de la selección, $\text{mediana}(\vec{R}_k, \vec{G}_k, \vec{B}_k) = (m_R, m_G, m_B)$ el vector que define la mediana del color de la selección, HSV el operador de transformación del espacio de coordenadas RGB a HSV, y $\text{HSV}(m_R, m_G, m_B) = (m_H, m_S, m_V)$ el vector de la mediana del color de la selección en el espacio HSV, queda entonces definida la máscara de color como

$$f(x, y) = (f_h(x, y), f_s(x, y), f_v(x, y)) \quad (24)$$

$$f_u(x, y) = \begin{cases} 1 & -\Lambda_u < u_{x,y} - m_u < \Lambda_u \\ 0 & \text{sino} \end{cases} \quad (25)$$

donde Λ es el límite para cada propiedad u , siendo estas Hue, Saturation o Value. Una vez obtenida la máscara $f(x, y)$ se realiza la operación AND entre la máscara y la imagen original, logrando obtener una intensidad nula en los píxeles de la imagen que no posean un color cercano a la mediana calculada como se puede ver en las Figuras (15a) y (15b).



(a) Video antes de aplicar la máscara siguiendo al objeto azul.



(b) Video después de aplicar la máscara. Es con esta imagen que opera el algoritmo y no con la normal.

Figura 15: Comparación entre video normal y luego de aplicar la máscara.

Este filtrado de color no solo posee una gran sinergia con el método de obtención de features de Shi-Tomasi, dado que este frame tiene bordes de mucha mejor calidad, sino que también posee una gran sinergia con el método de Optical Flow, debido a que como se ven menos bordes en la imagen modificada, aumenta notablemente la probabilidad de que los features queden contenidos todos dentro, o sobre los bordes del objeto a seguir.

Volviendo al caso de los objetos *A* y *B*:

- Si *A* y *B* son de colores distintos, con el filtro de color, el algoritmo nunca detecta que existe un objeto *B* por lo que seguirlo es imposible. Por consecuencia, se sigue únicamente a *A* y no se tiene el problema de *A* pasando por frente de *B*.
- Si *A* y *B* son de colores distintos, y *A*, el objeto a seguir, pasa por detrás de *B*, ahora no se adosan las features al objeto *B*, sino que el algoritmo ve que el área de *A* se achica a medida que este queda oculto por *B*. Como los features no tienen bordes para seguir, estos desaparecen, por lo que se deja de entregar mediciones al filtro de Kalman y este estima correctamente la posición de *A* mientras que este no haya sufrido aceleración alguna mientras estaba oculto.



(a) Ventana con el funcionamiento normal del seguidor, el cual utiliza un círculo naranja para detallar donde se encuentra el objeto a seguir.



(b) Ventana la cual solo aparece al seleccionar el modo debug. Aquí se muestra si el filtro de color se encuentra activado, el video luego de pasar por la máscara de color, las features del objeto como puntos verdes y la zona de búsqueda si se diese el caso de tracking failure.

Figura 16: Resultado de la selección de un elemento.

III-B2. Búsqueda del Objeto Perdido: Sin embargo, el filtro de Kalman no puede estimar la posición del objeto indefinidamente. Es por esto que cuando el objeto se pierde, es decir, no se logran detectar más features, se entra en otra fase del programa. En esta fase, se realiza una búsqueda del objeto en cada frame del video a partir de la estimación del filtro de Kalman y el tamaño original del área seleccionada. La altura y el ancho del área de búsqueda se incrementa por un factor constante por cada frame en la que la búsqueda falle. Esta búsqueda se basa en aplicar el algoritmo de Shi-Tomasi sobre el área mencionada.

III-B3. Corrección Periódica de los Puntos Característicos: Finalmente, para reforzar el algoritmo de seguimiento, se implementó además una recalculación periódica de las features con el método de Shi-Tomasi. Se parte de la media del cúmulo de features, removiendo los outliers, volviendo a calcular nuevamente la media y utilizar esta posición para aplicar el algoritmo de Shi-Tomasi, de la misma manera que se realiza sobre la primera selección proporcionada por el usuario. Todo esto permite subsanar varios de los problemas planteados anteriormente, sin embargo, existen aún otros problemas.

III-B4. Escenarios de fallas: Algunos casos donde puede fallar hasta ahora el Tracker son:

- El cambio de trayectoria de un objeto una vez que desaparece, provocando una falla en la predicción.
- Interacción entre el objeto trackeado y un objeto de características similares, causando un error de detección
- Cambios bruscos de iluminación o en color del objeto.

III-C. Último diseño

En la última iteración del proceso de diseño se sacrificó bajo costo computacional por una mayor robustez en el algoritmo, reduciendo significativamente las probabilidades de:

- Error tipo I: no se encuentra el objeto a seguir por más que sea visible.
- Error tipo II: se detecta un objeto por más que el objeto a seguir no se encuentre en pantalla.
- Error tipo III: se detecta a otro objeto por más que el objeto a seguir este visible.

mediante el uso de *Matched Filters*. Además, se logró obtener una gran robustez frente a cambios en la iluminación utilizando un algoritmo alternativo de enmascaramiento basado en la distribución de hue del objeto a seguir. Por último, se desarrolló una interfaz gráfica donde se puede cargar un video o bien utilizar una cámara en tiempo real, seguir varios objetos a la vez, modificar cualquier parámetro de cualquiera de los algoritmos utilizados en tiempo real e incluso se desarrolló un método de optimización automática de los parámetros del algoritmo de enmascaramiento. En la Figura (18) se puede observar una captura de la interfaz gráfica desarrollada y en la Figura (17) se puede observar el diagrama de flujo entero del algoritmo de seguimiento desarrollado. La Figura (20) aporta una visión de cómo se organiza el programa mencionado.

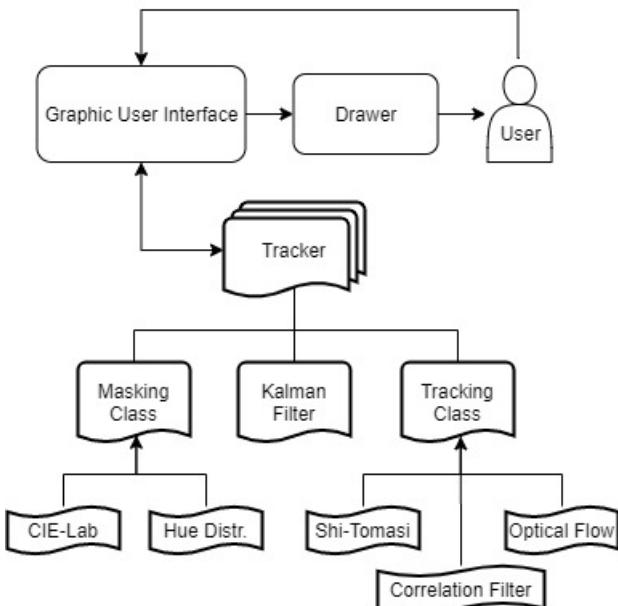


Figura 20: Diagrama de Clases del programa utilizado para presentar la funcionalidad del algoritmo desarrollado.

III-C1. Enmascaramiento Basado en CIE-Lab: El diseño anterior poseía un algoritmo de enmascaramiento basado en el espacio de color HSV. Si bien este funcionaba correctamente, este espacio de color fue reemplazado por CIE-Lab debido a que este posee un solo parámetro que caracteriza la iluminación de un objeto, es decir, con un valor nulo de L se obtiene el negro, mientras que con un valor máximo de L se obtiene blanco, pasando entre medio de esos dos valores por el color representado por a y b. En el espacio HSV, si se utiliza el máximo valor de la componente value,

no necesariamente se obtiene blanco, sino que depende del valor de saturación elegido, mientras que si value es nulo, siempre se obtiene negro. Poseer un solo parámetro que correctamente caracterice la iluminación de un objeto brinda una mejor optimización de los valores de semiamplicitudes L-a-b utilizados en el enmascaramiento.

La generación de la máscara se realiza de la misma forma que en el diseño anterior, con el único agregado de un suavizamiento de la máscara computada previo a la utilización de esta para el filtrado de la imagen. Esto se utiliza debido a que generalmente los bordes de un objeto poseen mayor o menor iluminación dependiendo de dónde este la fuente de luz más cercana. Estas diferencias en la iluminación pueden ocasionar que un objeto de similar color al de interés sea vez correctamente excluido de la imagen a excepción de sus bordes, lo cual genera problemas al pasar por delante o por detrás del objeto a seguir por causas detalladas anteriormente.



Figura 21: Ejemplo del uso del suavizado de la máscara de color. La segunda foto es la máscara previo al suavizado y la tercera foto es posterior al suavizado.

Sin embargo, si bien la utilización del espacio de color CIE-Lab subsanó varios problemas, el enmascaramiento de la imagen tomando en cuenta solamente uno de los varios colores del objeto a seguir falla cuando se encuentra en pantalla un objeto del mismo color que el utilizado para la

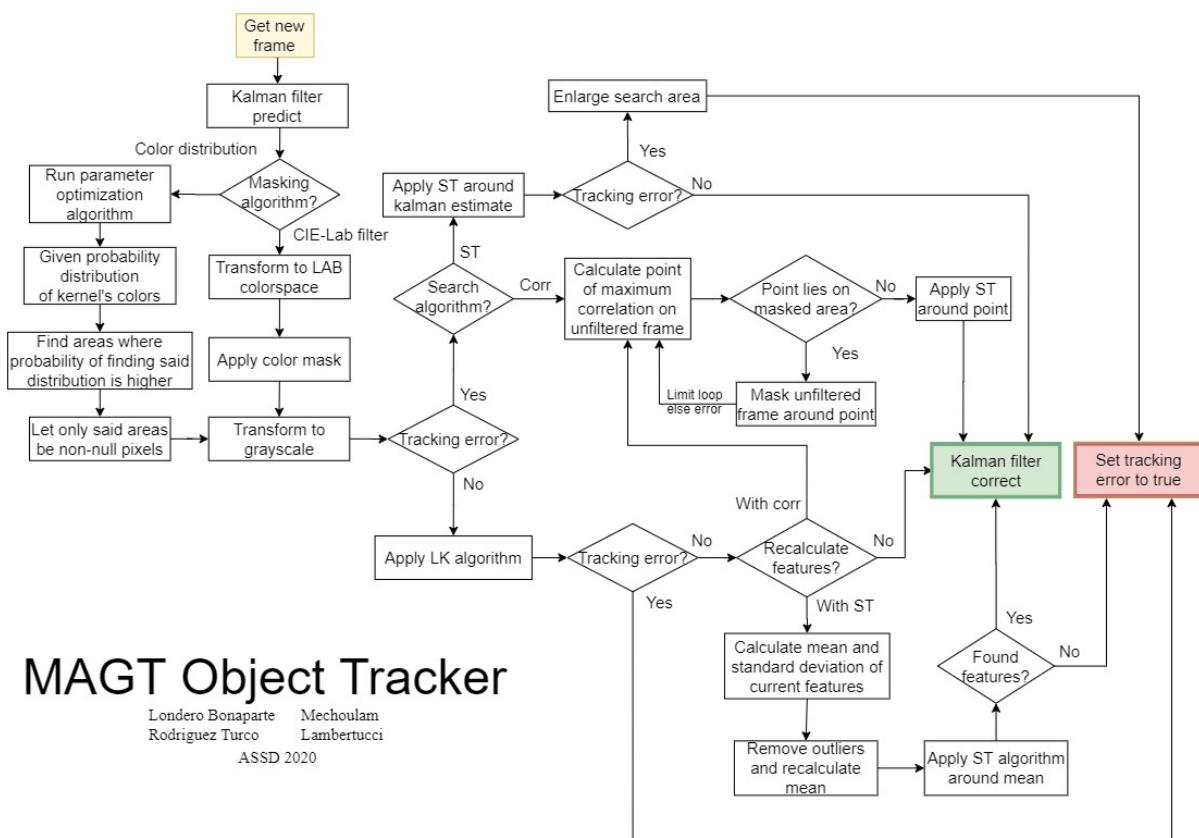


Figura 17: Flow-chart del algoritmo.

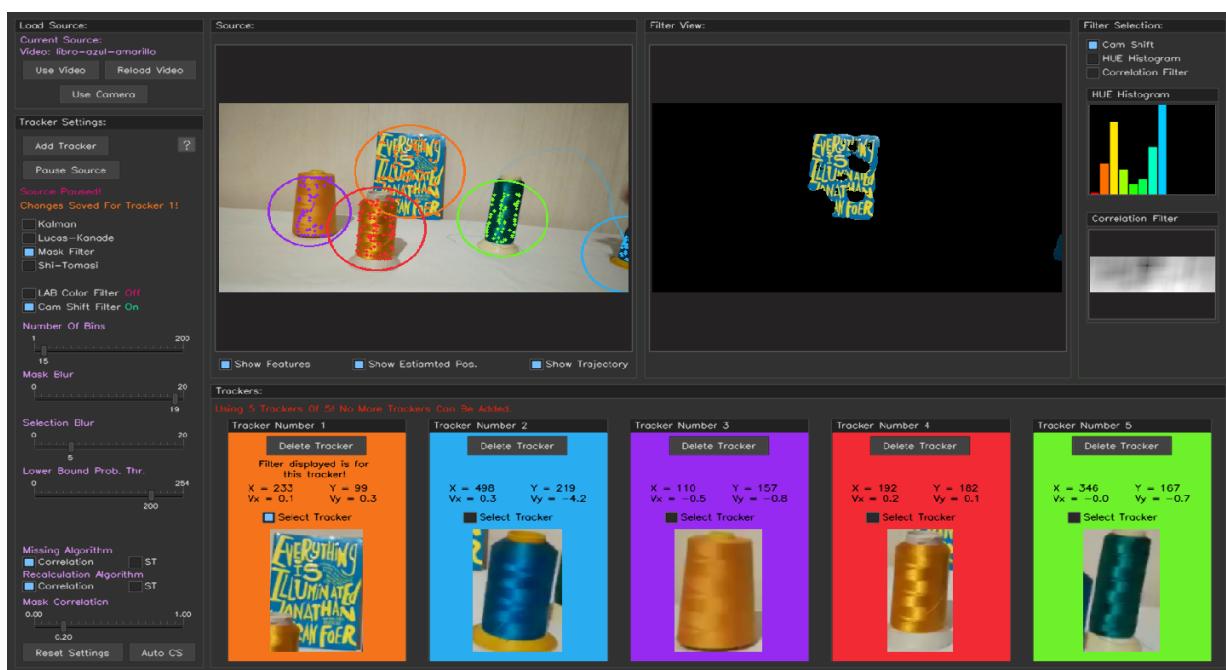


Figura 18: Captura de pantalla de la interfaz gráfica desarrollada.

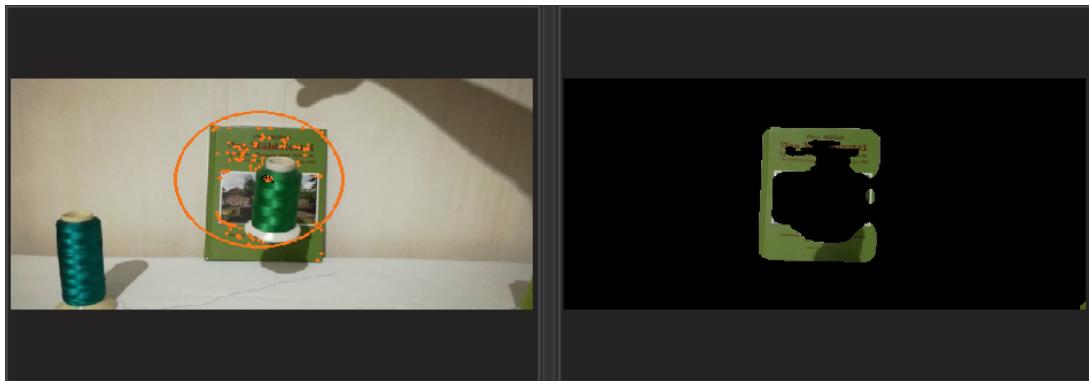


Figura 19: Primer ejemplo del algoritmo de enmascaramiento basado en camshift. En este ejemplo se puede notar la eficiencia conseguida en la máscara, debido a que por más que se encuentren varios objetos en escena de un color muy similar al objeto de interés, estos son excluidos por la máscara. Además, y de mayor importancia, se puede notar como el algoritmo de enmascaramiento no excluye la zona del libro bajo sombra. Esto muestra la gran robustez frente a cambios en la iluminación del algoritmo.

máscara. Para lidiar con este problema, se decidió desarrollar un método de enmascaramiento que tenga en cuenta todos los colores del objeto a seguir.

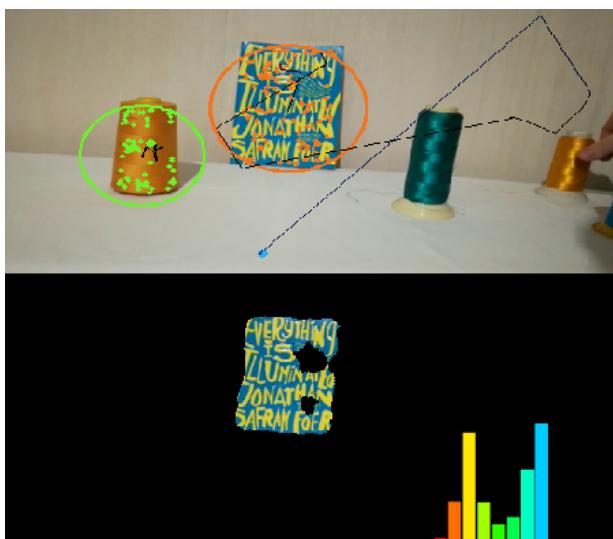


Figura 22: Segundo ejemplo del algoritmo de enmascaramiento basado en camshift. Se observa como el enmascaramiento se realiza a partir de la distribución de colores y no de los colores por separado, dado que por más que los carretes de hilo azules y amarillos posean colores dentro de la selección original (el libro), estos son excluidos por el algoritmo de enmascaramiento. Se editó a posteriori el histograma de colores de la selección sobre la imagen ya filtrada.

III-C2. Enmascaramiento Basado en Camshift:

III-C3. Algoritmo de Optimización de los Parámetros del Algoritmo de Enmascaramiento: le cambie el nombre a la sección por este porque seguramente pueda hacer andar optimize.shgo de scipy con el filtro de LAB que tiene los parametros rikis continuos

III-C4. Algoritmo correlación: Para el algoritmo de correlación no solo se utiliza el filtro explicado en

la Sección II-D, sino que además se trata tanto al frame como al kernel, aplicando una transformación al espacio HSV y allí un filtrado bajo las siguientes especificaciones:

$$MSK = H \in (0, 180) \quad S \in (50, 255) \quad V \in (32, 255) \quad (26)$$

Este filtrado del kernel logra eliminar aquellos pixeles de muy baja saturación (grises) y de muy bajo valor (negros), lo cual se comprobó experimentalmente que aumenta considerablemente la precisión en el algoritmo. Luego, se utiliza el filtro de correlación y se obtiene el punto donde esta es mayor. Se toma una sección alrededor de este punto proporcional a la selección inicial y se compara con el frame original. Si no comparten las características de color que son calculadas por el enmascaramiento de color o distribución de color, este punto de correlación es desecharido. Esto se logra aplicando una máscara en la sección del frame de mayor correlación, realizando sobre este nuevamente el cálculo de máxima correlación. Este proceso se realiza unas pocas veces con el propósito de no comprometer la velocidad de procesamiento entre frames. En caso de no encontrar al objeto se considera que hubo un error de trackeo (ocultación del objeto).



Figura 23: Aplicación del algoritmo de correlación con máscara.

Este algoritmo es utilizado en dos escenarios. En el primero se utiliza para la búsqueda de un objeto perdido. En caso de oclusión se utiliza el algoritmo para encontrar nuevamente el objeto, siendo efectivo siempre que no haya objetos que comparten tanto forma y color con el de interés. Por otro lado, en caso de que así sea y el objeto de interés se encuentre oculto, es posible que el algoritmo devuelva un falso positivo, siendo conveniente utilizar el alternativo de Shi-Tomasi y medias móviles, dado que el tener información de la posición previa para el tracking resulta fundamental para poder distinguir entre estos.

El otro escenario es utilizar la correlación para el recálculo periódico de features, esto es beneficioso cuando se da la interacción de dos objetos A y B siendo A el de interés y B uno similar. Si B pasa por delante de A quitandole las features, el cálculo periódico por correlación puede detectar que se está siguiendo a B y no a A , por lo que corrige este error. Una situación similar a esta no puede ser resuelta por el algoritmo de Shi-Tomasi con medias móviles.

III-C5. Optimización del Código: Se realizó una optimización del código, quitando redundancias y utilizando únicamente librerías que son corridas en C++ con la finalidad de que el procesamiento en tiempo real sea eficiente. Se optó por un enfoque OOP, esto permitió escalar el proyecto y obtener

una mayor modularidad.

Además se diseñó una GUI con la capacidad de trackeo multi-objeto, personalización de algoritmos, contando con la opción de variar algoritmos tanto de búsqueda como de recálculo entre medias móviles y correlación, al igual que filtrado por color o camshift. Existe la opción de cambiar las especificaciones de los filtros en tiempo real para obtener el filtro óptimo o que un algoritmo de optimización las calcule automáticamente. También se permiten diversas pantallas de debug, es decir, observar los distintos filtros a la vez, al igual que una estimación de la posición y velocidad del objeto. Finalmente cuenta con la capacidad de utilizar tanto un video en tiempo real como un video pre-existente.

III-C6. Escenarios de fallas: Si bien se han minimizado las probabilidades de cometer errores de tipo I y tipo II, aún se plantean los siguientes problemas:

- El algoritmo se encuentra en su situación más frágil al haber un objeto idéntico o de gran similaridad tanto en color como en forma con el que se quiere seguir, debido a que ni el filtro de distribución de color ni el filtro de correlación lograrán distinguir entre ambos. En este caso la única distinción entre ambos será la retención de esquinas características al objeto correcto proporcionado por el algoritmo de Optical Flow.
- La correcta elección de parámetros de los algoritmos encargados de la fase de enmascaramiento para cada situación proporcionan una gran robustez frente a cambios en la iluminación. Sin embargo, cuanto más robusto frente a cambios en la iluminación es el algoritmo, mayor será la probabilidad de cometer errores del tipo II (seguir a un objeto incorrecto) debido a que el enmascaramiento tendrá una mayor permisividad.

IV. CONCLUSIONES

Se desarrolló un algoritmo capaz de seguir a un objeto frente a oclusiones parciales y totales, cambios en la iluminación y cambios bruscos en su trayectoria. Se logró minimizar la probabilidad de cometer error de tipo I, tipo II y tipo III mencionados anteriormente utilizando una combinación de varios algoritmos y técnicas distintas, entre ellas: Sparse Optical Flow de Lucas Kanade para la detección de movimiento; el algoritmo de Shi-Tomasi para la búsqueda de esquinas características de un

objeto; filtros de Kalman para lograr estimar la trayectoria frente a una occlusión total; la utilización de filtros de distribución de color para detectar al objeto a seguir según su distribución de color y la probabilidad de ubicar esta distribución en la pantalla junto a filtros de color utilizando el espacio de colores CIE-Lab para el enmascaramiento de las zonas sin interés de la pantalla; y finalmente filtros de correlación adaptativos para desambiguar el seguimiento de un objeto solamente tomando como característica su color, lo cual reduce significativamente la probabilidad de seguir a un objeto de mismo color que el seleccionado.

REFERENCIAS

- [1] R. C. Gonzalez, R. E. Woods y S. L. Eddins. *Digital Image Processing Using MATLAB*. Prentice Hall, 2da ed, 2002.
- [2] R. C. Gonzalez, R. E. Woods y S. L. Eddins. *Digital Image Processing Using MATLAB*. Prentice Hall, 2da ed, 2002, pp. 52-54.
- [3] D. H. Warren y Edward R. Strelow. *Electronic Spatial Sensing for the Blind: Contributions from Perception*. Springer Netherlands, 1er ed, 1985. pp. 414.
- [4] B. D. Lucas y T. Kanade. *An iterative image registration technique with an application to stereo vision*. De Proceedings of Imaging Understanding Workshop, pp. 121-130.
- [5] J. Shi y C. Tomasi. *Good Features to Track*. 9th IEEE Conference on Computer Vision and Pattern Recognition, June 1994, Springer, pp. 593–600.
- [6] W.S.P. Fernando, L. Udawatta , P. Pathirana. *Identification of Moving Obstacles with Pyramidal Lucas Kanade Optical Flow and k means Clustering*. Faculty of Engineering, University of Moratuwa, Sri Lanka.
- [7] G. Terejanu, "Discrete Kalman Filter Tutorial", Cse.sc.edu, 2020. [Online]. Available: <https://cse.sc.edu/tterejanu/files/tutorialKF.pdf>. [Accessed: 15- Jun- 2020].
- [8] G. Welch and G. Bishop, An Introduction to the Kalman Filter. University of North Carolina at Chapel Hill: Department of Computer Science, 2006.
- [9] J. Shi y C. Tomasi. *Good Features to Track*. 9th IEEE Conference on Computer Vision and Pattern Recognition, June 1994, Springer, pp. 593–600.
- [10] G. Turin, "An introduction to matched filters," in IRE Transactions on Information Theory, vol. 6, no. 3, pp. 311-329, June 1960, doi: 10.1109/TIT.1960.1057571.